

Système de Détection d'Intrusions dans un Réseau IoT Simulé basé sur MQTT et l'Intelligence Artificielle

Ahrarache Anas¹ Mohamed Ait Ezzaouite¹ Nadir Mounim¹

¹Département Informatique, FST Tanger, Université Abdelmalek Essaâdi, Maroc

Résumé

Cet article présente la conception et l'implémentation d'un Système de Détection d'Intrusions (IDS) appliqué à un réseau IoT simulé basé sur le protocole MQTT. Notre approche combine une extraction de caractéristiques comportementales en temps réel dans Node-RED et un classificateur Random Forest pour identifier quatre types de trafic : normal, flooding, spoofing et anomalie de données. L'architecture modulaire en cinq couches — simulateurs Python, broker Mosquitto, orchestrateur Node-RED, API Flask et tableau de bord temps réel — est entièrement déployable localement. Le modèle, entraîné sur 513 fenêtres temporelles de 30 secondes générées depuis les simulateurs, atteint **100%** de précision sur l'ensemble de test (0 faux négatifs, 0 faux positifs). Les tests en conditions réelles confirment une latence de détection inférieure à 30 secondes et des scores de confiance supérieurs à 96%.

Mots-clés : IoT, MQTT, IDS, Machine Learning, Random Forest, Node-RED, Flask, Détection d'intrusions, Sécurité réseau.

1. INTRODUCTION ET CONTEXTE

L'Internet des Objets (IoT) connaît une croissance sans précédent : plus de 15 milliards de dispositifs connectés en 2025, avec une projection supérieure à 25 milliards d'ici 2030 [1]. Des capteurs de température, des actionneurs industriels et des passerelles de données échangent en permanence via des protocoles légers, dont **MQTT** est le plus répandu dans les architectures embarquées.

Cette expansion s'accompagne d'une surface d'attaque considérablement élargie. Les dispositifs IoT, contraints en ressources calcul, mémoire et énergie, ne peuvent pas embarquer des mécanismes de sécurité classiques. De surcroît, MQTT n'intègre *par défaut* aucune authentification ni chiffrement [2] : tout client peut se connecter à un broker, publier sur n'importe quel topic et lire les messages des autres abonnés.

- Connexion anonyme sans authentification
- Transmission des messages en clair (texte brut)
- Abonnements ouverts à tous les topics
- Aucun contrôle de fréquence de publication
- Absence de validation du contenu des messages

Les solutions IDS traditionnelles (analyse de paquets réseau, signatures) sont mal adaptées à ce contexte : elles requièrent un accès privilégié aux couches TCP/IP, sont trop lourdes pour les passerelles IoT, et ne voient pas les attaques qui restent dans les limites du protocole applicatif [5].

Ce travail répond à cette problématique en proposant un IDS à détection d'anomalies comportementales, opérant *exclusivement* au niveau applicatif MQTT, sans accès réseau privilégié.

2. ÉTAT DE L'ART

2.1 Sécurité IoT et IDS

La littérature distingue trois catégories d'IDS pour l'IoT [5] :

(1) **Par signatures** : comparaison du trafic à une base d'attaques connues. Efficace mais aveugle aux attaques inconnues (*zero-day*).

(2) **Par anomalies** : modélisation du comportement normal, alerte sur tout écart significatif. Plus adapté à l'IoT car ne nécessite pas de signatures prédéfinies.

(3) **Par apprentissage automatique** : apprentissage automatique des patterns de chaque classe. Offre le meilleur compromis entre généralisation et précision [4].

2.2 Travaux Connexes

Hindy *et al.* [3] ont publié le dataset MQTT-IoT-IDS2020, premier benchmark dédié aux attaques MQTT, atteignant 99,79% de précision avec Random Forest sur des features de flux réseau (niveau TCP/IP). Cette approche suppose cependant un accès à la couche réseau, indisponible dans notre architecture applicative.

Des travaux récents [6] sur Mirai et autres botnets IoT montrent que les attaques modernes combinent flooding massif et usurpation d'identité de dispositifs légitimes : deux classes directement adressées par notre système.

2.3 Choix de l'Algorithme : Random Forest

Après comparaison de plusieurs algorithmes (Tableau 1), le Random Forest a été retenu pour six raisons :

1. **Explicabilité** : importance des features native
2. **Robustesse** : ensemble d'arbres, résistance au bruit
3. **Performances** : >99% sur les benchmarks IoT-MQTT
4. **Pas de normalisation** des features requise
5. **Rapidité d'inférence** : prédiction quasi-instantanée
6. **Interprétabilité** : matrice de confusion analysable

Table 1 – Comparaison des algorithmes ML pour l'IDS IoT

Algorithme	Préc.	Explic.	Vitesse
Random Forest	Élevée	Bonne	Rapide
SVM	Moy.	Faible	Lente
Rés. Neurones	Élevée	Nulle	Moy.
Arbre Décision	Moy.	Excel.	Rapide
k-NN	Var.	Moy.	Lente


3. ARCHITECTURE GLOBALE

3.1 Vue en Cinq Couches

L'architecture suit un pipeline en cinq couches fonctionnelles découplées (Figure 1). Chaque couche peut être remplacée ou étendue indépendamment.

Table 2 – Couches de l'architecture IDS

#	Couche	Technologie	Port
1	Simulation	Python + paho-mqtt	—
2	Broker MQTT	Mosquitto 2.1.2	1883
3	Orchestration	Node-RED v4.1.10	1880
4	Moteur IA	Flask + RandomForest	5000
5	Tableau bord	Flask/SSE Dashboard	5000

**Figure 1** – Pipeline de détection en 5 couches

3.2 Flux de Données

1. Le simulateur publie un JSON MQTT au broker (port 1883)
2. Mosquitto route le message vers Node-RED (abonné `iot/devices/#`)
3. Node-RED accumule les messages dans une fenêtre glissante de 30 secondes par `device_id` et calcule 10 features
4. Les features sont envoyées en POST à `/predict`
5. Flask retourne `prediction`, `confidence`, `is_attack`
6. Node-RED aiguille vers ALERT ou NORMAL
7. Le dashboard se met à jour via Server-Sent Events (SSE)

4. PARTIE IOT

4.1 Capteurs et Actionneurs Simulés

L'environnement matériel est entièrement simulé : quatre scripts Python reproduisent le comportement de capteurs température/humidité réels. Les valeurs sont générées selon une distribution gaussienne $\mathcal{N}(\mu, \sigma)$ pour modéliser le bruit naturel des capteurs :

Table 3 – Paramètres des dispositifs simulés

Script	Temp.	Humid.	Intervalle	Classe
normal_device	$\mathcal{N}(22, 1.5)$	$\mathcal{N}(60, 3)$	5s	normal
attacker_flood	$\mathcal{N}(22, 1.5)$	$\mathcal{N}(60, 3)$	4s	flood
attacker_spoof	87°C fixe	5% fixe	5s	spoof
attacker_anomaly	34–39°C	21–26%	5s	anomaly

Chaque message publié contient :

```

1 {
2   "device_id": "device1",
3   "timestamp": "2026-05-29T12:07:21Z",
4   "temperature": 22.47,
5   "humidity": 58.32,
6   "payload_size": 149,
7   "msg_count": 42
8 }

```

4.2 Communication MQTT

Le broker Mosquitto est configuré pour écouter en local :

```

1 listener 1883 localhost
2 allow_anonymous true

```

La hiérarchie de topics suit le schéma :

`iot/devices/{device_id}/data`

La figure 2 montre les logs de Mosquitto : démarrage sur les sockets IPv4/IPv6, connexion de Node-RED (client `nodredd51c7...`), abonnement au wildcard `iot/devices/#`, et échanges keepalive toutes les 60 secondes.

```

Microsoft Windows [Version 10.0.26280.8457]
(c) Microsoft Corporation. All rights reserved.

C:\Users\PC>C:\Program Files\mosquitto\mosquitto.exe -c "D:\IOT IDS\mosquitto.conf" -v
1779979313: mosquitto version 2.1.2 starting
1779979313: Config loaded from D:\IOT IDS\mosquitto.conf.
1779979313: Bridge support available.
1779979313: Persistence support available.
1779979313: TLS support available.
1779979313: TLS-PSK support available.
1779979313: Websockets support available.
1779979313: Opening ipv6 listen socket on port 1883.
1779979313: Opening ipv4 listen socket on port 1883.
1779979313: mosquitto version 2.1.2 running
1779979333: New connection from 127.0.0.1:59179 on port 1883.
1779979333: New client connected from 127.0.0.1:59179 as nodredd51c7c85cb293122 (p4, c1, k60).
1779979333: No will message specified.
1779979333: Sending CONNACK to nodredd51c7c85cb293122 (0, 0)
1779979333: Received SUBSCRIBE from nodredd51c7c85cb293122
1779979333: iot/devices/# (QoS 0)
1779979333: nodredd51c7c85cb293122 0 iot/devices/#
1779979333: Sending SUBACK to nodredd51c7c85cb293122
1779979393: Received PINGREQ from nodredd51c7c85cb293122
1779979393: Sending PINGRESP to nodredd51c7c85cb293122
1779979453: Received PINGREQ from nodredd51c7c85cb293122
1779979453: Sending PINGRESP to nodredd51c7c85cb293122
1779979513: Received PINGREQ from nodredd51c7c85cb293122
1779979513: Sending PINGRESP to nodredd51c7c85cb293122
1779979573: Received PINGREQ from nodredd51c7c85cb293122
1779979573: Sending PINGRESP to nodredd51c7c85cb293122

```

Figure 2 – Logs Mosquitto : démarrage et connexion de Node-RED

```

[device1] Simulation stopped by user.
D:\IOT IDS\simulation-python normal_device.py device1
D:\IOT IDS\simulation-python normal_device.py:47: DeprecationWarning: Callback API version 1 is deprecated, update to latest version
client = mqtt.Client(client_id=DEVICE_ID)
[device1] Starting simulation. Publishing every 5s...
[device1] Connected to broker at localhost:1883
[device1] Topic: iot/devices/device1/data

[device1] msg#0001 | temp=23.47°C | hum=58.38% | size=1498
[device1] Message delivered (mid=1)
[device1] msg#0002 | temp=26.38°C | hum=62.36% | size=1488
[device1] Message delivered (mid=2)
[device1] msg#0003 | temp=22.22°C | hum=58.69% | size=1498
[device1] Message delivered (mid=3)
[device1] msg#0004 | temp=19.01°C | hum=60.33% | size=1498
[device1] Message delivered (mid=4)
[device1] msg#0005 | temp=22.53°C | hum=65.54% | size=1498
[device1] Message delivered (mid=5)
[device1] msg#0006 | temp=17.88°C | hum=58.38% | size=1498

```

Figure 3 – Simulateur `normal_device.py` — sorties console `device1`

La figure 3 confirme la publication à intervalle de 5s avec des valeurs gaussiennes réalistes (19°C–26°C) et la livraison confirmée à chaque message.

4.3 Node-RED — Orchestration

Node-RED joue le rôle de couche d'intégration entre le broker MQTT et le moteur IA. Le flow (Figure 4) enchaîne :




Figure 4 — Flow Node-RED — pipeline complet de détection

1. **MQTT-in** — abonné à `iot/devices/#`
2. **JSON** — désérialisation du payload
3. **Feature Extractor** (fonction) — fenêtre 30s par device, calcul des 10 features
4. **Flask AI API** (HTTP Request) — POST vers `:5000/predict`
5. **Is Attack?** (Switch) — aiguillage sur `is_attack`
6. **ALERT / NORMAL** (Debug) — sortie avec horodatage

Le panneau debug confirme : `device1` → normal (confidence=1.0), `device2` → flood (confidence=0.97).

4.4 Cloud / Stockage Local

Par choix délibéré, l'architecture est entièrement locale : **aucune dépendance à un service cloud**. Ce choix garantit la fiabilité lors des démonstrations et élimine la latence réseau. Une extension future avec InfluxDB + Grafana pour la persistance historique est prévue (voir Section 7).

5. PARTIE INTELLIGENCE ARTIFICIELLE

5.1 Objectif de l'IA

L'objectif est de classer chaque fenêtre temporelle de 30 secondes en l'une des quatre classes : **normal**, **flood**, **spoof**, **anomaly**. La classification doit être :

- **Temps réel** : décision en moins de 10 ms
- **Robuste** : résistante au bruit naturel des capteurs
- **Explicable** : importance des features justifiable
- **0 faux négatifs** : priorité sécurité absolue

5.2 Données Utilisées

5.2.1 Rejet des Datasets Publics

Deux datasets publics ont été évalués et rejetés :

MQTT-IoT-IDS2020 [3] utilise des features TCP/IP (durée de flux, taille de paquets) extraites par Wireshark. Ces features sont **inaccessibles** depuis Node-RED qui ne voit que le contenu applicatif. Entraîner sur des features non observables en production est un anti-pattern fondamental de machine learning.

5.2.2 Génération du Dataset

Un script `collect_data.py` souscrit au broker MQTT et collecte les *mêmes* fenêtres de 30 secondes que Node-RED produit en production, garantissant la cohérence totale train/déploiement.

Table 4 — Protocole de collecte du dataset

Session	Classe	Durée	Fenêtres
1	normal	20 min	129
2	flood	20 min	138
3	spoof	20 min	126
4	anomaly	20 min	120
Total	4 classes	80 min	513

5.2.3 Les 10 Features Comportementales

Table 5 — Features extraites par Node-RED (fenêtre 30s/device)

#	Feature	Attaque
1	msg_count	flood
2	mean_interval	flood
3	std_interval	flood
4	mean_payload_size	spoof, anomaly
5	mean_temp	spoof, anomaly
6	std_temp	anomaly
7	mean_humidity	spoof, anomaly
8	std_humidity	anomaly
9	out_of_range_ratio	spoof
10	topic_depth	toutes

5.3 Modèle Choisi — Random Forest

5.3.1 Configuration

```
1 RandomForestClassifier(
2     n_estimators=100,
3     max_depth=10,
4     min_samples_split=5,
5     min_samples_leaf=2,
6     random_state=42,
7     n_jobs=-1
8 )
```

5.3.2 Séparation Train/Test

Séparation 80/20 avec stratification par classe :

- **Train** : 410 fenêtres
- **Test** : 103 fenêtres

La stratification garantit que la proportion de chaque classe est identique dans les deux ensembles.

5.4 Résultats Obtenus

5.4.1 Métriques de Classification

Table 6 — Rapport de classification — ensemble de test (103 samples)

Classe	Préc.	Rappel	F1	N
anomaly	1.00	1.00	1.00	24
flood	1.00	1.00	1.00	28
normal	1.00	1.00	1.00	26
spoof	1.00	1.00	1.00	25
accuracy			1.00	103

5.4.2 Matrice de Confusion

Table 7 — Matrice de confusion — 0 FP, 0 FN

Réel \ Prédit	anom.	flood	norm.	spoof
anomaly	24	0	0	0
flood	0	28	0	0
normal	0	0	26	0
spoof	0	0	0	25

5.4.3 Importance des Features

Table 8 – Importance des 10 features (Random Forest)

Rang	Feature	Imp.
1	mean_payload_size	19.8%
2	mean_interval	19.3%
3	mean_humidity	15.9%
4	mean_temp	14.5%
5	std_temp	11.2%
6	std_humidity	9.8%
7	msg_count	4.2%
8	std_interval	3.0%
9	out_of_range_ratio	1.3%
10	topic_depth	0.8%

Les deux features les plus discriminantes sont `mean_payload_size` (19.8%) et `mean_interval` (19.3%) : la première distingue spoof (payload fixe) du trafic normal, la seconde détecte le flood (4s vs 5s d'intervalle). Le `topic_depth` (0.8%) est quasi-constant pour tous les dispositifs (4 niveaux) et contribue peu à la discrimination.

5.4.4 API Flask de Prédiction

```

C:\IoT_IDS>python app.py
Model loaded. Classes: ['anomaly', 'flood', 'normal', 'spoof']
Starting flask API on http://localhost:5000
Dashboard: http://localhost:5000/dashboard
* Serving Flask app 'app'
* Debug mode: off
WARNING: This is a development server. Do not use it in a production deployment. Use a production WSGI server instead.
* Running on http://127.0.0.1:5000
* Running on http://192.168.11.206:5000

Press CTRL-C to quit
127.0.0.1 - [29/May/2026 12:06:48] "GET /dashboard HTTP/1.1" 200 -
127.0.0.1 - [29/May/2026 12:06:50] "GET /events HTTP/1.1" 200 -
127.0.0.1 - [29/May/2026 12:06:50] "GET /favicon.ico HTTP/1.1" 404 -
[PREDICT] normal (confidence=1.0000, device=device1)
127.0.0.1 - [29/May/2026 12:07:21] "POST /predict HTTP/1.1" 200 -
[PREDICT] normal (confidence=1.0000, device=device1)
127.0.0.1 - [29/May/2026 12:07:51] "POST /predict HTTP/1.1" 200 -
[PREDICT] normal (confidence=1.0000, device=device1)
127.0.0.1 - [29/May/2026 12:08:21] "POST /predict HTTP/1.1" 200 -
[PREDICT] normal (confidence=0.9933, device=device1)
127.0.0.1 - [29/May/2026 12:08:51] "POST /predict HTTP/1.1" 200 -
[PREDICT] flood (confidence=0.9600, device=device2)
127.0.0.1 - [29/May/2026 12:09:04] "POST /predict HTTP/1.1" 200 -
[PREDICT] normal (confidence=0.9907, device=device1)
127.0.0.1 - [29/May/2026 12:09:21] "POST /predict HTTP/1.1" 200 -
[PREDICT] flood (confidence=0.9700, device=device2)
127.0.0.1 - [29/May/2026 12:09:36] "POST /predict HTTP/1.1" 200 -

```

Figure 5 – API Flask — logs de prédiction en temps réel

La figure 5 confirme le chargement du modèle avec les 4 classes, les requêtes POST reçues toutes les 30 secondes, et les prédictions : `normal` (confidence=1.0000, device=device1) et `flood` (confidence=0.9600, device=device2).

L'endpoint POST `/predict` retourne :

```

1 {
2   "prediction": "flood",
3   "confidence": 0.97,
4   "is_attack": true,
5   "status": "ok"
6 }

```

6. RÉSULTATS ET DÉMONSTRATION

6.1 Tableau de Bord Temps Réel



Figure 6 – Dashboard IDS — localhost:5000/dashboard

La figure 6 montre le tableau de bord lors d'un test simultané `device1` (normal) + `device2` (flood). On observe :

- 7 détections totales, 2 attaques (rouge), 5 normales (vert), 2 dispositifs actifs
- Graphe temporel : courbe verte (normal) croît régulièrement, courbe rouge (flood) apparaît à 12h08:51
- Anneau de distribution : 71% normal / 29% flood
- Fil live : FLOOD 97%, NORMAL 99.7%, FLOOD 96%

6.2 Session de Test End-to-End

Table 9 – Détections live — session du 29/05/2026

Heure	Dev.	Préd.	Conf.	Interv.
12 :07 :21	dev1	NORMAL	100%	5.0s
12 :07 :51	dev1	NORMAL	100%	5.0s
12 :08 :21	dev1	NORMAL	100%	5.0s
12 :08 :51	dev1	NORMAL	99.3%	5.0s
12 :08 :51	dev2	FLOOD	96.0%	4.0s
12 :09 :04	dev1	NORMAL	99.7%	5.0s
12 :09 :21	dev2	FLOOD	97.0%	4.0s
12 :09 :36	dev2	FLOOD	97.0%	4.0s

- 0 erreur de classification sur toute la session
- Confiance $\geq 96\%$ sur toutes les prédictions
- Latence de détection : 30s (première fenêtre complète)
- Isolation correcte `device1` / `device2` dans Node-RED

6.3 Métriques Opérationnelles

Table 10 – Performances opérationnelles du système

Métrique	Valeur
Latence détection minimale	30 s
Temps inférence Flask	< 10 ms
Confiance minimale (live)	96%
Précision test	100% (103/103)
Faux négatifs	0
Faux positifs	0
Rafraîchissement dashboard	~30 s
Dispositifs supportés	Illimité

7. DISCUSSION, LIMITES ET PERSPECTIVES

7.1 Discussion

Les résultats confirment la validité de l'approche *application-layer behavioral IDS*. Le principe central : entraîner le modèle sur exactement les mêmes features qu'il observera en production (cohérence train/déploiement) est la clé de la précision de 100%.

La subtilité intentionnelle des attaques simulées (flood : 4s vs 5s, anomaly : valeurs à la limite du plausible) valide que le modèle *apprend* des patterns comportementaux et ne se contente pas de seuils triviaux détectables par des règles if/else.

7.1.1 FP vs FN : Priorité Sécurité

Un **Faux Négatif** (attaque non détectée) est plus dangereux qu'un **Faux Positif** (fausse alerte). Un FP coûte du temps d'analyse ; un FN peut coûter la confidentialité, l'intégrité ou la disponibilité du système.

Notre modèle : **0 FN**.

7.2 Limites Actuelles

- **Dataset de taille limitée** : 513 fenêtres sont insuffisantes pour un déploiement industriel. Un dataset de plusieurs milliers d'exemples, capturés dans des conditions variées, serait nécessaire.
- **Fenêtre fixe de 30s** : latence de détection incompressible de 30s. Une fenêtre glissante continue réduirait ce délai.
- **MQTT non chiffré** : le système opère sur le port 1883. Un déploiement réel utiliserait MQTTS (TLS, port 8883).
- **Pas de persistance** : les détections ne sont pas stockées. L'analyse historique et les tendances long terme ne sont pas disponibles.
- **Attaques non distribuées** : le système n'a pas été testé avec plusieurs attaquants simultanés sur des dispositifs différents.

7.3 Perspectives d'Amélioration

1. **InfluxDB + Grafana** : persistance des métriques et tableau de bord production-grade avec alertes configurables
2. **Online Learning** : adaptation continue du modèle aux évolutions du comportement normal
3. **MQTTS (TLS)** : authentification par certificats clients et chiffrement des communications
4. **Enrichissement du dataset** : collecte longue durée avec variations environnementales et redémarrages
5. **Attaques combinées** : flood + spoof simultanés, attaques distribuées multi-dispositifs
6. **Alertes actives** : notifications email/SMS/webhook déclenchées automatiquement
7. **Autres protocoles** : extension à CoAP, AMQP, Zigbee, Z-Wave

8. CONCLUSION

Ce travail démontre qu'un IDS efficace pour les réseaux IoT MQTT peut être construit en s'appuyant *exclusivement* sur des comportements applicatifs, sans accès aux couches réseau. L'alliance de Node-RED pour l'extraction de features temps réel et d'un Random Forest pour la classification produit un pipeline robuste, interprétable et directement déployable sur tout gateway IoT sans privilèges réseau.

La précision de **100%** sur l'ensemble de test (0 FN, 0 FP), confirmée par les tests live avec des scores de confiance de 96–100%, valide l'approche. La décision clé — générer un dataset cohérent avec les features réellement extractibles — illustre un principe fondamental de machine learning appliqué : la cohérence entre l'environnement d'entraînement et l'environnement de déploiement est une garantie non négociable.

Les cinq couches de l'architecture (simulation, broker, orchestration, IA, visualisation) sont totalement découplées : chaque composant est remplaçable indépendamment, rendant le système extensible vers des protocoles IoT additionnels, des modèles ML plus avancés, ou des infrastructures de persistance (InfluxDB, Grafana) sans

remise en cause de l'architecture globale.

RÉFÉRENCES

- [1] Statista Research Department, "Number of IoT connected devices worldwide 2019–2030," *Statista*, 2024.
- [2] OASIS Standard, "MQTT Version 5.0 Specification," OASIS Open, 2019. [Online]. Available : [https://docs.oasis-open.org/mqtt/mqtt/v5.0/](https://docs.oasis-open.org/mqtt/mqtt/v5.0/docs.oasis-open.org/mqtt/mqtt/v5.0/)
- [3] H. Hindy *et al.*, "MQTT IoT IDS2020 : MQTT Internet of Things Intrusion Detection Dataset," *IEEE DataPort*, 2020. [Online]. Available : <https://ieee-dataport.org/open-access/mqtt-iot-ids2020>
- [4] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [5] S. Sicari *et al.*, "Security, privacy and trust in Internet of Things : The road ahead," *Computer Networks*, vol. 76, pp. 146–164, 2015.
- [6] C. Koliadis *et al.*, "DDoS in the IoT : Mirai and other botnets," *Computer*, vol. 50, no. 7, pp. 80–84, 2017.
- [7] OpenJS Foundation, "Node-RED Documentation," 2024. [Online]. Available : <https://nodered.org/docs/>
- [8] F. Pedregosa *et al.*, "Scikit-learn : Machine learning in Python," *JMLR*, vol. 12, pp. 2825–2830, 2011.